

Методы анализа чувствительности

- Матрица коэффициентов влияния

- Прямое дифференцирование

Что такое анализ чувствительности и зачем чувствительность суровым инженерам

В самом общем смысле **анализ чувствительности** (sensitivity analysis, анализ матрицы/коэффициентов влияния) — это набор идей и техник, которые позволяют проанализировать (аналитически или численно) влияние параметров системы на ее отклик.

Анализ чувствительности является основой для таких приложений, как:

- **Анализ устойчивости** динамических систем к шумам (robustness).
- **Выявление ключевых факторов** — ранжирование параметров по степени их влияния на отклик системы.
- **Оптимизация параметров** системы с целью уменьшения неопределенности ее отклика. Локальные коэффициенты влияния используются для выбора направления оптимизации при использовании градиентных методов.

Сфера приложений может быть любой: от технических систем до экономики и социальных наук. Под системой может пониматься как некоторая математическая модель, так и, например, наблюдаемая действительность: технологический или экономический процесс.

Например, если под системой понимать техпроцесс получения материала с заданными физическими свойствами (теплопроводность, прочность и т. д.), то в качестве независимых параметров могут выступать характеристики техпроцесса (температура спекания, длительность и т. д.) и характеристики сырья. Для этой задачи мы можем эмпирическим путем варьировать входные параметры и смотреть, каким образом они влияют на выходные.

Самым простым подходом здесь будет **ANOVA** (ANalysis-Of-VAriance) — классический метод описательной статистики — или другие методы анализа вариации. Также для анализа может быть использована линейная регрессия. Однако методы анализа вариации и линейная регрессия могут очень плохо работать для нелинейных систем.

Как вариант, можно использовать **нейронные сети**, которые хорошо справляются с нелинейностями. После обучения на имеющемся корпусе данных «технологический параметр — свойство» анализ чувствительности можно проводить уже на математической (суррогатной) модели — это намного дешевле первого пути, так как данные уже существуют. Однако нейронные сети не являются в полной мере математической моделью, а представляют собой

скорее объект-интерполятор (*surrogate*). Они позволяют анализировать связи только между входным и выходным слоями, в то время как внутренняя структура системы ими игнорируется.

Наиболее полно с точки зрения математики система будет задана, если ее поведение описывается **дифференциальным уравнением**. В этом случае можно исследовать влияние коэффициентов этого уравнения или граничных условий на устойчивость системы, а также анализировать «распространение» ошибки в задании этих параметров до окончательного решения.

Наличие как аналитической, так и суррогатной модели позволяет анализировать влияние параметров путем «дифференцирования системы» по каждому из параметров в окрестности некоторой точки в пространстве параметров. Так как подобный анализ производится дифференцированием в некоторой окрестности точки в пространстве параметров, то подобный анализ называют **локальным**

Если система представима в какой-либо математической форме, например в виде дифференциального уравнения, то для ее дифференцирования можно использовать аналитические методы. Это самый быстрый подход когда число параметров невелико и связь между откликом системы и параметрами может быть сведена к уравнениям. Когда анализируется сложная система, которая может быть представлена в виде компьютерной программы, сюда же можно отнести и суррогатные модели, то аналитические выражения получить уже нереально и в таком случае для локального анализа может быть использовано **автоматическое, комплексное и конечно-разностное** дифференцирование. Для глобального исследования чувствительности а не только в окрестности некоторого значения параметров может быть использован метод Монте-Карло.

Как связаны производные и ошибки ?

Матрица ковариации и взвешенный метод наименьших квадратов (WLS)

Для линейной регрессии задача оценки параметров сводится к минимизации квадратичной формы ошибки:

$$\hat{\mathbf{b}} = \arg \min_{\mathbf{\beta}} (\vec{\mathbf{e}}^T \mathbf{W}^{-1} \vec{\mathbf{e}})$$

где $\vec{\mathbf{e}} = \vec{\mathbf{y}} - \mathbf{A}\mathbf{\beta}$ — вектор остатков модели, а $\mathbf{W}$ — весовая матрица.

Оценка параметров через псевдообратную матрицу:

Вектор оценок $\vec{\mathbf{b}}$ выражается через взвешенную псевдообратную матрицу $\mathbf{A}^\dagger$:

$$\vec{\mathbf{b}} = \mathbf{A}^\dagger \vec{\mathbf{y}} = (\mathbf{A}^T \mathbf{W}^{-1} \mathbf{A})^{-1} \mathbf{A}^T \mathbf{W}^{-1} \vec{\mathbf{y}}$$

Здесь предполагается, что весовая функция $\mathbf{W}$ задается с точностью до некоторой постоянной. Поскольку $\mathbf{A}^\dagger \mathbf{A} = \mathbf{I}$ (единичная матрица), а математическое ожидание ошибки $\mathbb{E}[\vec{\mathbf{e}}] = \vec{\mathbf{0}}$, оценка является несмещенной: $\mathbb{E}[\vec{\mathbf{b}}] = \vec{\mathbf{\beta}}$.

Трансформация ковариации:

Матрица ковариации для вектора параметров $\vec{b}$ вычисляется по закону распространения ошибки:

$$\text{Cov}(\vec{b}) = A^\dagger \Sigma (A^\dagger)^T \text{ где } \Sigma = \mathbb{E}[\vec{\epsilon}\vec{\epsilon}^T] \text{ — истинная матрица ковариации входных данных.}$$

Частные случаи:

1. **Некоррелированные измерения (Гетероскедастичность 📌):** Если каждая точка получена из распределения со своей дисперсией σ_i^2 , то матрица Σ будет диагональной. При условии оптимального выбора весов ($W = \Sigma$) выражение для матрицы ковариации параметров принимает вид: $\text{Cov}(\vec{b}) = (A^T W^{-1} A)^{-1}$ Сама матрица Σ при этом выглядит так:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \dots & 0 \\ 0 & \ddots & 0 \\ 0 & \dots & \sigma_N^2 \end{bmatrix}$$

2. **Все измерения имеют одну ошибку - равную точность (Гомоскедастичность 📌):** Если все экспериментальные точки получены из одного распределения с постоянной дисперсией σ^2 (т.е. $\Sigma = \sigma^2 I$), формула переходит в стандартный вид обыкновенного МНК:

$$\text{Cov}(\vec{b}) = (A^T A)^{-1} \sigma^2$$

Эта итоговая формула наглядно показывает, что погрешность оценки параметров обратно пропорциональна «величине» матрицы чувствительности $A^T A$.

Как мы помним для задачи линейной регрессии матрица первых производных функции остатков по искомым параметрам модели, это и есть матрица предикторов.

Для нелинейной регрессии

Задача нелинейной регрессии состоит в поиске такого вектора параметров $\vec{b}$, который минимизирует функционал невязки (меру ошибки):

$$\hat{b} = \arg \min_b \Phi(\vec{b})$$

Исходя из статистического предположения, что ошибки измерений распределены по закону Гаусса, метод максимального правдоподобия приводит к минимизации следующего функционала:

$$\Phi(\vec{b}) = \frac{1}{2} \vec{r}^T W^{-1} \vec{r} = \frac{1}{2} (f(\vec{b}) - \vec{y})^T W^{-1} (f(\vec{b}) - \vec{y})$$

Здесь вектор остатков $\vec{r}$ — это разница между предсказанием нелинейной модели $f(\vec{b})$ и вектором экспериментальных данных $\vec{y}$.

Градиент функции невязки будет:

$$\nabla_b \Phi(\vec{b}) = J^T W^{-1} (f_b - \vec{y})$$

J - матрица первых производных, $J_{ij} = \frac{\partial f_b}{\partial b_j}(x_i)$ или транспонированная ей матрица

Для оценки ковариации параметров в нелинейном случае используют матрицу вторых производных (Гессииан), рассчитанную в точке локального минимума $\vec{b}^*$:

$$\text{Cov}(\vec{b}^*) = \mathbb{E}[(\vec{b} - \vec{\beta})(\vec{b} - \vec{\beta})^T] \approx (J^T W^{-1} J + H)^{-1} \sigma^2$$

Как правило, вторыми производными самой модели (матрицей H) пренебрегают в силу их малости в окрестности решения. То есть, используется аппроксимация Гаусса-Ньютона:

$$\text{Cov}(\vec{b}) \approx (J^T W^{-1} J)^{-1} \sigma^2$$

Так как истинная величина дисперсии ошибок измерений часто неизвестна, для её оценки используют среднее квадратичное отклонение аппроксимации с учетом числа степеней свободы:

$$\sigma^2 \approx \frac{(f(\vec{b}^*) - \vec{y})^T W^{-1} (f(\vec{b}^*) - \vec{y})}{N - P}$$

Где:

- $f(\vec{b}^*)$ — отклик модели в найденной точке решения;
- N — количество экспериментальных точек;
- P — количество оцениваемых параметров.

Величину, обратную матрице ковариации, называют **информационной матрицей Фишера**. Она количественно определяет, сколько информации о параметрах содержится в проведенном эксперименте.

Резюме

1. **Матрица Якоби — это матрица чувствительности.** При решении обратной задачи (нелинейной регрессии) степень неопределенности параметров (ковариация) обратно пропорциональна чувствительности. Высокая чувствительность выходной характеристики модели (например, температуры в контрольных точках) к изменению параметров означает меньшую погрешность решения обратной задачи и более высокую точность идентификации свойств системы.

Геометрическая интерпретация (от ИИ): Представьте поверхность целевой функции (суммы квадратов невязок). Если чувствительность высокая, «яма» целевой функции очень крутая и узкая — вы четко попадаете в минимум. Если чувствительность низкая, «яма» превращается в плоское блюдо. Минимум размыт, и любое случайное отклонение (шум в данных) отбрасывает оценку параметра далеко от истины.

2. **Управление неопределенностью.** Очевидно, что неопределенность можно снизить, уменьшая дисперсию исходных данных (например, увеличивая число измерений), но это не всегда физически возможно. Однако мы можем повлиять на информативность данных через саму постановку эксперимента, увеличивая значения в матрице Якоби.

Таким образом, с задачей **анализа чувствительности** неразрывно связана задача **планирования эксперимента**. Основная идея заключается в том, чтобы подобрать такие условия (режимы нагрева, точки установки датчиков, длительность процесса), при которых система проявляет **максимальную чувствительность** именно к тем параметрам, которые мы хотим определить.

Это превращается в самостоятельную оптимизационную задачу: как организовать получение исходных данных так, чтобы извлечь из них максимум информации и получить минимально возможную вариацию искомых параметров модели.

Пример постановки задачи планирования эксперимента

Задача планирования теплофизического эксперимента может быть сформулирована следующим образом:

Найти точки оптимального расположения термодатчиков по глубине образца для идентификации температурной зависимости теплопроводности по их показаниям.

До проведения реального эксперимента мы можем проанализировать матрицу чувствительности прямой задачи. Для этого необходимо задать априорное (приблизительное) значение искомой теплопроводности, решить задачу для определения функций чувствительности и, имея зависимость матрицы Якоби от координат и времени, выбрать те точки, которые обеспечивают максимальную информативность.

Поскольку чувствительность описывается матрицей, для её максимизации используют специальные скалярные критерии оптимальности:

- **D-оптимальность:** Максимизация определителя информационной матрицы (или минимизация определителя обратной). Геометрически это означает минимизацию **объема эллипсоида неопределенности**. Несмотря на эффективность, этот критерий может приводить к неустойчивости, если эллипсоид сильно вытянут.
- **K-оптимальность (Conditioning):** Минимизация числа обусловленности (отношение максимального сингулярного значения к минимальному). Чем меньше это число, тем более **устойчиво** обращение матрицы и тем менее чувствителен результат к шумам измерений.
- **A-оптимальность:** Минимизация следа (*trace*) обратной информационной матрицы. Это эквивалентно минимизации **средней вариации** (суммы дисперсий) всех оцениваемых параметров.

Простой пример прямого дифференцирования

Начнем с относительно простой задачи, у нас есть экспериментальные данные $\vec{y}(t)$, где t - независимая переменная.

Некоторая модель $\vec{f}(t; \vec{a})$, которая должна описывать наблюдаемые $\vec{y}(t)$ имеет набор параметров $\vec{a}$, также известно, что для нахождения $\vec{f}(t; \vec{a})$ необходимо решить уравнение вида:

$$B(\vec{a})\vec{f}(t; \vec{a}) = A(\vec{a})\vec{y}_0 + \vec{b}(\vec{a})$$

Функция остатков (residuals):

$$r(\vec{t}, \vec{a}) = \vec{f} - \vec{y}$$

Скалярная функция невязки будет:

$$\Phi(\vec{a}) = \frac{1}{2} (\vec{f} - \vec{y})^T (\vec{f} - \vec{y})$$

Для решения задачи оптимизации градиентными методами необходимо знать градиент невязки по параметрам оптимизации:

$$\nabla_a \Phi(\vec{a}) = [\nabla_a \vec{f}] \cdot \vec{r}$$

В квадратных скобках стоит матрица Якоби, которую обозначают иногда

$$J = [\nabla_a \vec{f}] = \frac{d}{d\vec{a}} \vec{f}$$

Элементы этой матрицы соответствуют i -й координаты вектора $\vec{f}$ по j -й переменной оптимизации:

$$J_{ij} = \frac{\partial f_j}{\partial a_i}$$

Идея прямого дифференцирования состоит в том, чтобы параллельно с решением уравнения для нахождения $\vec{f}$ вычислить и матрицу Якоби

Так как для вычисления функции f у нас есть некоторая неявная схема, то самым простым вариантом является продифференцировать эту схему, чтобы получить несколько уравнений для векторов градиентов

$$B(\vec{a}) \vec{f}(t; \vec{a}) = A(\vec{a}) \vec{y}_0 + \vec{b}(\vec{a})$$

$$\frac{\partial}{\partial a_i} [B(\vec{a}) \vec{f}(t; \vec{a})] = \frac{\partial}{\partial a_i} A(\vec{a}) \vec{y}_0 + \frac{\partial \vec{b}}{\partial a_i}$$

$$\frac{\partial B}{\partial a_i} \vec{f}(t; \vec{a}) + B \frac{\partial \vec{f}}{\partial a_i} = \frac{\partial A}{\partial a_i} \vec{y}_0 + \frac{\partial \vec{b}}{\partial a_i}$$

$\frac{\partial \vec{f}}{\partial a_i}$ - это соответственно столбец матрицы Якоби

Выражение можно переписать так:

$$B \frac{\partial \vec{f}}{\partial a_i} = \frac{\partial A}{\partial a_i} \vec{y}_0 - \frac{\partial B}{\partial a_i} \vec{f}(t; \vec{a}) + \frac{\partial \vec{b}}{\partial a_i} \quad (2)$$

Соответственно мы получаем M уравнений чувствительности, для векторов производных $\frac{\partial \vec{f}}{\partial a_i}$, где M - число переменных оптимизации (число строк матрицы Якоби)

Кроме того мы должны решить еще само исходное уравнение для нахождения $\vec{f}$:

$$B(\vec{a}) \vec{f}(t; \vec{a}) = A(\vec{a}) \vec{y}_0 + \vec{b}$$

Какие тут основные моменты:

1. Для того чтобы вычислить матрицу Якоби, нам нужно решить $M+1$ уравнений
2. В выражении (2) одна и та же левая часть (матрица B), меняется только правая часть
3. Метод легко встроить в конечно - разностные или конечно - элементные схемы, например, для конечно разностной схемы типа Кранка-Николсона:

Прямое дифференцирование на примере решения коэффициентной обратной задачи для уравнения теплопроводности

Постановка прямой задачи

Итак мы решаем уравнение нелинейное нестационарное уравнение теплопроводности для распределения температуры в слое однородного изотропного материала толщиной H в следующей форме:

$$\frac{\partial T}{\partial t} = a(T) \frac{\partial^2 T}{\partial x^2} + a(T) \frac{\lambda'(T)}{\lambda(T)} \left(\frac{\partial T}{\partial x} \right)^2$$

$$a(T) = \frac{\lambda(T)}{C(T)} - \text{температуропроводность}$$

$$\lambda'(T) = \frac{d\lambda}{dT} - \text{производная теплопроводности по температуре}$$

С граничными условиями первого рода:

$$T(x, t)|_{x=0} = f(t), t \in [0, t_m]$$

$$T(x, t)|_{x=H} = g(t), t \in [0, t_m]$$

И начальными условиями:

$$T(x, 0) = \phi(x), x \in [0, H]$$

Постановка параметрической обратной задачи

Наша задача - найти температурную зависимость теплопроводности по набору зависимостей температуры от времени, измеренным в k точках по толщине образца

$$[\vec{y}|_{x_1}, \dots, \vec{y}|_{x_k}]$$

Основная идея параметрической оптимизации, состоит в том, чтобы сделать предположения о форме температурной зависимости от времени, сохранив несколько параметров неопределенными, и, далее, подобрать эти параметры при помощи того или иного метода оптимизации.

Для определенности предположим, что температурная зависимость теплопроводности описывается полиномом некоторого произвольного базиса:

$$\lambda(T) = \sum_{i=1}^M b_i \beta_i(T)$$

где b_i - постоянные коэффициенты, не зависящие от температуры, а $\beta_i(T)$ - базисные функции (мономиалы), например, для стандартного базиса $\beta_i(T) = T^{i-1}$

Так как в уравнение входит не только сама теплопроводность, но и ее производная по температуре, то, так как коэффициенты производной полинома можно выразить через коэффициенты исходного полинома, то оставим пока их в таком виде

$$\lambda'(T) = \sum_{i=1}^M b'_i(\vec{b}) \beta_i(T)$$

Конкретная форма зависимости $b'_i(\vec{b})$ будет определяться типом полинома.

Функция остатков (residuals):

$$\vec{r}(t, \vec{b}) = \text{vcat}_k(\vec{T}(t, \vec{b})|_{x_k} - \vec{y}_k)$$

Здесь vcat это операция превращения векторов в матрицу, которая просто складывает вектора в один вектор так как, допустим, если у нас есть несколько точек измерения x_k

Конкретный вид функции невязки пока не принципиален, это может быть функция правдоподобия или квадратичная форма. Для определенности пусть невязка между измеренными зависимостями температуры от времени и рассчитанными - обычная квадратичная форма с весовой матрице Q (что предполагает Гауссову ошибку):

$$\Phi(\vec{a}) = \frac{1}{2} \vec{r}^T W \vec{r}$$

Зависимости температур от времени $\vec{T}(t, \vec{b})|_{x_k}$ для нескольких координат получаются из решения уравнения теплопроводности.

Градиент выражается в виде:

$$\nabla_b \Phi(\vec{b}) = J^T W^{-1} \vec{r}$$

где J - матрица Якоби

Далее тут возможно несколько вариантов формулировок для вычисления матрицы чувствительности, **дискретный** и **непрерывный**

Непрерывный подход к прямому дифференцированию основан на прямом дифференцировании непосредственно дифференциального уравнения.

Дискретный - на дифференцировании дискретного представления этого уравнения, например, конечно-разностной схемы.

Непрерывный подход

Тут получается, что так как параметры оптимизации входят в коэффициенты уравнения, то есть, от них зависит сам дифференциальный оператор, то, следовательно, и решение этого уравнения будет зависеть от этих параметров.

Обозначим производную по параметру оптимизации b_i как :

$$J_i = \frac{dT}{db_i}$$

Очень важный для понимания момент состоит в том, что производная в данном случае должна учитывать полную вариацию решения при изменении параметров оптимизации, некоторые из членов уравнения зависят от параметров оптимизации в явном виде, но некоторые зависят опосредованно, через собственно решение задачи.

Поэтому важно, что здесь стоит именно полная производная!

Задача состоит в том, чтобы продифференцировать исходное уравнение и получить M новых уравнений для J_i . Для этого продифференцируем исходное уравнение по b_i :

$$\frac{d}{db_i} \frac{\partial T}{\partial t} = \frac{d}{db_i} [a(T) \frac{\partial^2 T}{\partial x^2}] + \frac{d}{db_i} [a(T) \frac{\lambda'(T)}{\lambda(T)} (\frac{\partial T}{\partial x})^2]$$

Прежде чем взять все и продифференцировать, необходимо разобраться с полной производной.

Мы помним, что зависимость теплопроводности от параметров оптимизации линейна:

$$\lambda(\vec{b}, T) = \sum_{i=1}^M b_i \beta_i(T)^{(**)}$$

Казалось бы, производная теплопроводности $\lambda(T)$ по b_i будет просто $\beta_i(T)$. Но в действительности, нельзя забывать, что, так как теплопроводность входит в сам дифференциальный оператор, температура, которая является решением дифференциального уравнения, в уравнении $(**)$ также будет зависеть от параметров оптимизации. Поэтому, при варьировании параметра b_i температура также будет меняться.

Так как теплопроводность зависит от температуры, то при варьировании параметра b_i , ее изменение произойдет не только вследствие собственно изменения параметра b_i (которое определяется частной производной по b_i), но и вследствие изменения температуры - отклика дифференциального оператора на варьирование b_i .

Поэтому уравнение $(**)$ более точно следует записать как:

$$\lambda(\vec{b}, T(\vec{b})) = \sum_{i=1}^M b_i \beta_i(T(\vec{b}))$$

Для расчета производной сложной функции нужно пользоваться цепным правилом дифференцирования (chain rule):

$$\frac{df(x(t), y(t))}{dt} = \frac{\partial f}{\partial x} \frac{dx}{dt} + \frac{\partial f}{\partial y} \frac{dy}{dt}$$

Если переменная t входит в явном виде, то chain-rule дает нам:

$$\frac{df(t, x(t))}{dt} = \frac{\partial f}{\partial t} \frac{dt}{dt} + \frac{\partial f}{\partial x} \frac{dx}{dt} = \frac{\partial f}{\partial t} + \frac{\partial f}{\partial x} \frac{dx}{dt}$$

Для примера посмотрим на дифференцирование температуропроводности. Так как теплоемкость по условию задачи не зависит от параметров оптимизации, влияние варьирования b_i на нее

происходит только за счет отклика диффура. При этом сама теплопроводность зависит от переменной оптимизации в явном виде.

$$\frac{da(T(\vec{b}), \vec{b})}{db_i} = \frac{d}{db_i} [\lambda(\vec{b}, T(\vec{b})) / C(T(\vec{b}))] = \frac{1}{C(T)} \frac{\partial \lambda}{\partial b_i} + \frac{\partial [\lambda(T) / C(T)]}{\partial T} \frac{dT}{db_i}$$

Или, с учетом правила цепного дифференцирования дает :

$$\frac{da(T, \vec{b})}{db_i} = \frac{d}{db_i} [\lambda(\vec{b}, T) / C(T)] = \frac{\beta_i}{C} + \frac{\lambda' C - C' \lambda}{C^2} J_i$$

Напомним, что $\beta_i(T)$ - известная функция полиномиального базиса

Теперь можно перейти непосредственно к дифференцированию уравнения с целью получения уравнений для компонент матрицы Якоби.

$$\frac{d}{db_i} \left[\frac{\partial T}{\partial t} \right] = \frac{d}{db_i} \left[a(T) \frac{\partial^2 T}{\partial x^2} + a(T) \frac{\lambda'(T)}{\lambda(T)} \left(\frac{\partial T}{\partial x} \right)^2 \right]$$

В левой части мы имеем:

$$\frac{d}{db_i} \left[\frac{\partial T}{\partial t} \right] = \frac{\partial}{\partial t} \frac{dT}{db_i} = \frac{\partial J_i}{\partial t}$$

То есть, мы поменяли местами порядок дифференцирования. Это накладывает определенные ограничения, во-первых функция должна быть непрерывна, во-вторых (и третьих) обе производные должны быть непрерывны.

Аналогичный фокус мы можем проделать и с остальными производными.

$$\frac{\partial J_i}{\partial t} = a \frac{\partial^2 J_i}{\partial x^2} + T_{xx} \frac{\lambda' C - C' \lambda}{C^2} J_i + T_{xx} \frac{\beta_i}{C} + \frac{d}{db_i} \left[a(T) \frac{\lambda'}{\lambda} \left(\frac{\partial T}{\partial x} \right)^2 \right]$$

Теперь посчитаем самую навороченную производную - от правой части.

Пользуясь правилом цепного дифференцирования, тройное произведение дает:

$$\frac{d}{db_i} \left[a \frac{\lambda'}{\lambda} T_x^2 \right] = (I) \frac{d}{db_i} [a(T, b)] \frac{\lambda'}{\lambda} T_x^2 + (II) a(T) \frac{d}{db_i} \left[\frac{\lambda'(T, b)}{\lambda(T, b)} \right] T_x^2 + (III) a \frac{\lambda'}{\lambda} \frac{d}{db_i} [T_x^2]$$

(в квадратных скобках стоит то, что дифференцируем)

Начнем с конца.

Третье слагаемое:

$$(III) : a \frac{\lambda'}{\lambda} \frac{d}{db_i} [T_x^2] = 2a \frac{\lambda'}{\lambda} T_x \frac{\partial J_i}{\partial x}$$

Первое слагаемое:

$$(I) : \frac{d}{db_i} [a(T, b)] \frac{\lambda'}{\lambda} T_x^2 = \left[\frac{\beta_i}{C} + \frac{\lambda' C - C' \lambda}{C^2} J_i \right] \frac{\lambda'}{\lambda} T_x^2 = \frac{\lambda'}{\lambda} T_x^2 \frac{\lambda' C - C' \lambda}{C^2} J_i + \frac{\lambda'}{\lambda} T_x^2 \frac{\beta_i}{C}$$

Второе слагаемое - самое сложное, так как и производная и сама функция теплопроводности зависят от параметров оптимизации, но оно также легко расписывается при помощи цепного

дифференцирования.

$$(II) : aT_x^2 \frac{d}{db_i} \left[\frac{\lambda'(T,b)}{\lambda(T,b)} \right]$$

$$\frac{d}{db_i} \left[\frac{\lambda'(T,b)}{\lambda(T,b)} \right] = \frac{\partial}{\partial b_i} \left[\frac{\lambda'}{\lambda} \right] + \frac{\partial}{\partial T} \left[\frac{\lambda'}{\lambda} \right] J_i$$

$$\frac{\partial}{\partial b_i} [\lambda' / \lambda] = \frac{[\partial_{b_i} \lambda'] \lambda - \lambda' \beta_i}{\lambda^2}$$

Здесь $\partial_{b_i} \lambda'$ - это производная производной теплопроводности по параметрам оптимизации, как уже упоминалось, коэффициенты полинома для производной могут быть выражены через коэффициенты полинома исходной функции, но конкретная форма этой связи зависит от полиномиального базиса, поэтому оставим пока в таком виде.

$$\text{А также с учетом того, что: } \frac{\partial}{\partial T} [\lambda' / \lambda] \frac{dT}{db_i} = \frac{\lambda'' \lambda - (\lambda')^2}{\lambda^2} J_i$$

Правило цепного дифференцирования дает:

$$a(T) T_x^2 \frac{d}{db_i} \left[\frac{\lambda'(T,b)}{\lambda(T,b)} \right] = aT_x^2 \left[\frac{[\partial_{b_i} \lambda'] \lambda - \lambda' \beta_i}{\lambda^2} + \frac{\lambda'' \lambda - (\lambda')^2}{\lambda^2} J_i \right] = aT_x^2 \frac{[\partial_{b_i} \lambda'] \lambda - \lambda' \beta_i}{\lambda^2} + aT_x^2 \frac{\lambda'' \lambda - (\lambda')^2}{\lambda^2} J_i$$

Теперь соберем все вместе:

$$\begin{aligned} \frac{\partial J_i}{\partial t} &= a \frac{\partial^2 J_i}{\partial x^2} + T_{xx} \frac{\lambda' C - C' \lambda}{C^2} J_i + T_{xx} \frac{\beta_i}{C} + \\ &+ \left[\frac{\beta_i}{C} + \frac{\lambda' C - C' \lambda}{C^2} J_i \right] \frac{\lambda'}{\lambda} T_x^2 + \\ &+ aT_x^2 \left[\frac{[\partial_{b_i} \lambda'] \lambda - \lambda' \beta_i}{\lambda^2} + \frac{\lambda'' \lambda - (\lambda')^2}{\lambda^2} J_i \right] + 2a \frac{\lambda'}{\lambda} T_x \frac{\partial J_i}{\partial x} \end{aligned}$$

Уравнение выглядит немного громоздко, надо его структурировать, для этого нужно сгруппировать коэффициенты перед $\frac{\partial J_i}{\partial t}$, $\frac{\partial^2 J_i}{\partial x^2}$, $\frac{\partial J_i}{\partial x}$ и J_i

Необходимо отметить, что само распределение температуры и его производные являются известными для уравнения чувствительности.

Уравнение выше можно представить в следующей форме, сгруппировав члены при производных функции чувствительности:

$$\frac{\partial J_i}{\partial t} = a(T) \frac{\partial^2 J_i}{\partial x^2} + V(x, t) \frac{\partial J_i}{\partial x} + G(x, t) J_i + F_i$$

В этом выражении :

$$V = 2a(T) \frac{\lambda'}{\lambda} T_x$$

Коэффициент $G(x, t)$

$$G(x, t) = T_{xx} \left[\frac{\lambda' C - C' \lambda}{C^2} \right] + \frac{\lambda'}{\lambda} T_x^2 \left[\frac{\lambda' C - C' \lambda}{C^2} \right] + aT_x^2 \left[\frac{\lambda'' \lambda - (\lambda')^2}{\lambda^2} \right]$$

Выражение для последнего члена суммы:

$$F_i = \frac{\beta_i(T)}{C(T)} T_{xx} + \frac{\beta_i(T)}{C(T)} \frac{\lambda'(T)}{\lambda(T)} T_x^2 + a T_x^2 \frac{[\partial_{b_i} \lambda'] \lambda - \lambda' \beta_i(T)}{\lambda^2}$$

Так как начальное распределение температуры, равно как и функции, задающие граничные условия первого рода, не зависят от теплопроводности, граничные и начальные условия для функций влияния будут нулевыми.

Окончательно задача запишется в виде:

$$\frac{\partial J_i}{\partial t} = a \frac{\partial^2 J_i}{\partial x^2} + V(x, t) \frac{\partial J_i}{\partial x} + G(x, t) J_i + F_i$$

А функции T_x и T_{xx} получаются путем решения исходного уравнения.

С нулевыми граничными условиями первого рода:

$$J_i|_{x=0, x=b} = 0, t \in [0, t_m]$$

И нулевыми начальными условиями:

$$J_i(x, 0) = 0, x \in [0, b]$$

где, коэффициент диффузии:

$$V = 2a \frac{\lambda'}{\lambda} T_x$$

Коэффициент перед первой производной по координате

$$G(x, t) = T_{xx} \left[\frac{\lambda' C - C' \lambda}{C^2} \right] + \frac{\lambda'}{\lambda} T_x^2 \left[\frac{\lambda' C - C' \lambda}{C^2} \right] + a T_x^2 \left[\frac{\lambda'' \lambda - (\lambda')^2}{\lambda^2} \right]$$

Последний член - функция источников:

$$F_i = \frac{\beta_i}{C} T_{xx} + \frac{\beta_i}{C} \frac{\lambda'}{\lambda} T_x^2 + a T_x^2 \frac{[\partial_{b_i} \lambda'] \lambda - \lambda' \beta_i}{\lambda^2}$$

Можно заметить несколько аспектов, которые позволяют упростить вычисления:

1. Коэффициенты G и V не зависят от β_i , следовательно, если у нас есть решение исходного ДУ (то есть известны T, T_t, T_x, T_{xx}) эти коэффициенты будут одинаковыми для всех дифференциальных уравнений
2. Если коэффициент теплопроводности не зависит от температуры, то $\beta_1 = 1$, все коэффициенты, содержащие производную теплопроводности по температуре станут равными нулю, останется только первый член F_i и часть коэффициента G , мы получим уравнение для чувствительности:

$$\frac{\partial J_i}{\partial t} = a \frac{\partial^2 J_i}{\partial x^2} - a T_{xx} \left[\frac{C'}{C} \right] J_i + \frac{1}{C} T_{xx}$$

Надо также сказать пару слов про расчет $\partial_{b_i} \lambda'$, входящей в выражение для функции источников

Прямое дифференцирование конечно-разностной схемы (дискретный подход):

Для примера рассмотрим конечно-разностную схему второго порядка по времени и координате (схема Кранка-Николсона, подробно разные схемы рассматривались на семинаре 27)

$$C^m \vec{T}^{m+1} = N^m \vec{T}^m + \vec{b}^m$$

m - это индекс момента времени, то есть, вектор $\vec{T}^m$ - это соответственно распределение температуры по толщине образца в m -й момент времени. Соответственно данная система уравнений решается итерационно в цикле, стартую с моменты времени $t_1 = 0.0$, в который распределение температуры по толщине задается начальными условиями. Помимо решения данной системы, также на каждом шаге применяются граничные условия которые меняют первые и последние строки матриц и вектор нелинейной части.

Сами матрицы выражаются следующим образом:

$$C^m = \begin{bmatrix} 1 + F_1^m & -\frac{1}{2}F_1^m & 0 & \dots & 0 \\ -\frac{1}{2}F_2^m & 1 + F_2^m & -\frac{1}{2}F_2^m & \dots & 0 \\ 0 & -\frac{1}{2}F_3^m & 1 + F_3^m & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & -\frac{1}{2}F_{N-1}^m \\ 0 & 0 & 0 & -\frac{1}{2}F_N^m & 1 + F_N^m \end{bmatrix}$$

и

$$N^m = \begin{bmatrix} 1 - F_1^m & \frac{1}{2}F_1^m & 0 & \dots & 0 \\ \frac{1}{2}F_2^m & 1 - F_2^m & \frac{1}{2}F_2^m & \dots & 0 \\ 0 & \frac{1}{2}F_3^m & 1 - F_3^m & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \frac{1}{2}F_{N-1}^m \\ 0 & 0 & 0 & \frac{1}{2}F_N^m & 1 - F_N^m \end{bmatrix}$$

нелинейный член: $[\vec{b}^m(\vec{T}^m)]_n = F_n^m \phi_n^m(T_{n-1}^m - T_{n+1}^m)^2$

Который также может быть записан в матричной форме через произведение Адамара (поэлементное умножение матриц)

Существенным образом зависит от параметров оптимизации.

$$\vec{b}^m(\vec{T}^m) = \text{diag}(\vec{F}^m \circ \vec{\phi}^m)(D\vec{T}^m \circ D\vec{T}^m)$$

$F_n^m(\vec{p}) = \frac{\alpha_n^m \Delta t}{\Delta x^2}$ - число Фурье, зависит от параметров $\vec{p}$, задающих свойства материала

$\phi_n^m(\vec{p}) = \frac{\lambda_n^m}{4\lambda_n^m}$ - коэффициент нелинейной части

Дифференцирование конечно-разностной схемы

Чтобы получить уравнение для столбца матрицы чувствительности $\vec{J}^m = \frac{\partial \vec{T}^m}{\partial \vec{p}}$,

продифференцируем исходную конечно-разностную схему Кранка-Николсона по параметру $\vec{p}$:

$$C^m \vec{T}^{m+1} = N^m \vec{T}^m + \vec{b}^m$$

1. Общий вид шага по времени

Применяя правило дифференцирования произведения к обеим частям уравнения, получаем:

$$C^m \frac{\partial \vec{T}^{m+1}}{\partial p} + \frac{\partial C^m}{\partial p} \vec{T}^{m+1} = N^m \frac{\partial \vec{T}^m}{\partial p} + \frac{\partial N^m}{\partial p} \vec{T}^m + \frac{\partial \vec{b}^m}{\partial p}$$

Перегруппировав слагаемые относительно искомого вектора $\vec{Z}^{m+1}$, получаем итерационную схему:

$$C^m \vec{J}^{m+1} = N^m \vec{J}^m + \left[\frac{\partial N^m}{\partial p} \vec{T}^m - \frac{\partial C^m}{\partial p} \vec{T}^{m+1} + \frac{\partial \vec{b}^m}{\partial p} \right]$$

2. Производные матриц системы

Матрицы производных $\frac{\partial C^m}{\partial p}$ и $\frac{\partial N^m}{\partial p}$ сохраняют **трехдиагональную структуру** исходных матриц (а это значит что можно использовать быстрые алгоритмы), где вместо коэффициентов F_n^m стоят их производные по параметру:

$$\frac{\partial C^m}{\partial p} = \begin{bmatrix} \frac{\partial F_1^m}{\partial p} & -\frac{1}{2} \frac{\partial F_1^m}{\partial p} & 0 & \dots \\ -\frac{1}{2} \frac{\partial F_2^m}{\partial p} & \frac{\partial F_2^m}{\partial p} & -\frac{1}{2} \frac{\partial F_2^m}{\partial p} & \dots \\ 0 & -\frac{1}{2} \frac{\partial F_3^m}{\partial p} & \frac{\partial F_3^m}{\partial p} & \dots \\ \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

3. Дифференцирование нелинейного вектора источника

Для компонент вектора $[\vec{b}^m]_n = F_n^m \phi_n^m (T_{n-1}^m - T_{n+1}^m)^2$ производная по параметру вычисляется по цепному правилу:

$$\frac{\partial [\vec{b}^m]_n}{\partial p} = \frac{\partial F_n^m}{\partial p} \phi_n^m (T_{n-1}^m - T_{n+1}^m)^2 + F_n^m \frac{\partial \phi_n^m}{\partial p} (T_{n-1}^m - T_{n+1}^m)^2 + 2F_n^m \phi_n^m (T_{n-1}^m - T_{n+1}^m) \cdot (Z_{n-1}^m - Z_{n+1}^m)$$

Резюме:

Для решения задачи чувствительности используются **те же матрицы системы** C^m и N^m , что и для основной температурной задачи. Это позволяет экономить ресурсы и что немаловажно использовать тот же решатель.

Метод прямого дифференцирования кажется наиболее предпочтительным для задачи планирования эксперимента, так как на выходе мы имеем зависимости матрицы якоби от времени и координаты, а, следовательно можно легко решать задачу планирования эксперимента, то есть, например, выбрать расположение датчиков температур таким образом, чтобы получить максимальную чувствительность.